RQ1 错误分类整理与合并材料

DAB 既有实验 · 当前分类 v0.3 · 整理日期 2026年10月31日

本材料回答：数据分析 Agent 的最终未通过结果主要涉及哪些错误机制，不同信息模式下呈现什么差异，以及双方后续如何统一分类。现有证据显示，未通过运行主要集中在数据处理与算法实现、必要信息缺失或歧义、求解流程失效三类。

分析范围与统计口径

对象为17个数据集、104道题，覆盖4个模型、3种模式和Pandas、Polars、Ibis、PySpark四个后端，共4,992条最终有效运行。同一题跨设置的运行有关联；重试不另外计作独立样本。每条未通过运行只统计一个主要小类，可另保留多个过程标签。[S1-S3]

当前3,191条通过（63.9%），1,801条未通过（36.1%）。未通过中包括1,533条评测判错、218条生成超时、50条其他未有效评分；最后一组为49条缺少输出及1条评测超时，不能全称为“答案错误”。

正式主分类分布

类别	名称	数量	占未通过
I1	任务理解与分析方案错误	96	5.3%
I2	数据选择与解释错误	146	8.1%
I3	数据处理与算法实现错误	695	38.6%
I4	API、执行与修复失败	9	0.5%
I5	指令落实与结果交付错误	26	1.4%
I6	求解流程失效	213	11.8%
II1	任务口径与必要信息缺失或歧义	593	32.9%
II3	输出约定缺失	12	0.7%
II4	澄清信息不充分、错误或矛盾	11	0.6%

I类为Agent能力或执行失败：1,185条，占65.8%；II类为任务信息与澄清不足：616条，占34.2%。I3、II1、I6合计1,501条，占83.3%。百分比分母均为1,801条未通过运行；四舍五入可能带来合计误差。[S3]

分类定义与判定边界

分类依据是本次运行中可见的信息、实际行为和结果之间的证据关系。I类要求相关规则已明确或可从允许数据中确定；II类要求必要信息仍有缺口或澄清不可靠。一个任务可在不同运行中出现不同错误，不能把题目永久贴为I类或II类。[S2]

小类	纳入依据
I1 任务理解与分析方案错误	必要规则可确定，但整体任务理解或方案不成立；即使程序按该方案执行正确，也无法满足目标。
I2 数据选择与解释错误	相关目标和方案成立，错误落在具体数据源、字段、记录或已有明确含义的值的选择与解释。
I3 数据处理与算法实现错误	应做的操作可确定，但筛选、关联、聚合、类型、空值、日期、文本或必要解码方法实现有误或缺失。
I4 API、执行与修复失败	未解决的接口、参数、语法、依赖或路径错误直接阻碍最终完成；已修复的异常仅记过程标签，真实服务中断不归此类。
I5 指令落实与结果交付错误	已有正确计算结果，却未按明确要求提交文件、结构、精度或顺序；仅缺答案文件不足以判此类。
I6 求解流程失效	时间线表明无效循环，或关键求解 / 验证阶段未收束且预算终止；须记录阶段和停止方式，不能只看超时。
II1 任务口径与必要信息缺失或歧义	影响答案的必要口径无法由当次题面、允许数据和实际澄清确定；存在有证据联系的合理解释竞争。
II3 输出约定缺失	评测要求特定排序、舍入或空结果表示等输出约定，但当次任务未明确提供。
II4 澄清信息不充分、错误或矛盾	实际澄清未可靠补足被询问的必要规则，或给出错误、矛盾信息，并与该次失败有关。

优先核对的五组边界

I1 / I2 / I3：先核查信息是否充分，再区分整体方案、具体数据映射、操作实现。不能从“结果不对”倒推方案错误。

I类 / II1：没写字段名、没给提示、模型没提问，都不是信息缺失的充分证据；可从题面与数据确定的事实，应由模型自行检查。

I4 / I6：具体未解决异常可直接解释失败时按其证据判断；超时只是结果状态，I6还须有未收束阶段或无效循环的时间线。

I5 / II3：输出要求明确但未落实，且已有正确内容，才支持I5；评测依赖未公开约定则检查II3。

II4 / 未落实正确回答：回答本身错误或不足才检查II4；正确回答未落实，仍按实际方案、数据或实现错误归类。

II2已合并到II1，沿用现有编号。U表示证据不足，Q表示任务或评测合同疑点；二者是证据状态，不增加理论类别。主因无法区分时保留候选，不硬选。

代表案例与证据索引

以下为帮助对齐边界而选择的九个案例，不用于估计类别占比。案例来自既有正式标注；详细题面、轨迹、代码、评测及证据限制保存在随附案例索引，不能把简写当作完整因果证明。[S4]

I1 任务理解与分析方案错误

imdb / task3 · GPT-5.5 · clarified · ibis。题目要分别找字母顺序最前的演员和影片，模型先选第一位演员，再只在她的影片里选第一部，额外加了配对限制。

证据限制：这是已保存的开发期I1裁定；两个最小值的语义边界有讨论记录，不声称本次重建了参考全集。

I2 数据选择与解释错误

imdb / task9 · GPT-6 · clarified · pyspark。题目列举具体写作署名，模型用了更粗的writer角色大类，纳入不符合这些署名的作者。

证据限制：没有直接告诉列名不等于缺信息；本例的字段层级区分经开发讨论确认。字符串取最小本身无误。

I3 数据处理与算法实现错误

crmarenapro / task9 · GLM-5.3 · interact · pandas。关联账号编号前没有统一空格和前导#，部分慢工单未能关联到州，导致州均值改变，原答案IL；既有单因素只读诊断统一编号后得到MI。

证据限制：既有当前数据诊断复现旧输出；该运行原始输入与现存数据的完整哈希关联尚未完成。本次不重跑解法。

I4 API、执行与修复失败

cve / task1 · GLM-5.3 · clarified · polars。最后两个求解版本仍因字符映射KeyError报错，诊断后没有修复完成的执行证据，最终达到时限。

证据限制：此前候选答案164已保存，不能写成没有答案；也不能把这个旧候选视为最后版本成功。管道exit0掩盖异常，正式评测跳过。

I5 指令落实与结果交付错误

stockmarket / task1 · GLM-5.3 · clarified · pandas。已算出正确数值18.44，却把answer保存成数字；题面明确要求字符串，交付被拒收。

证据限制：主因是已有正确内容未按明确合同交付，不是只凭missing_output来判I5。

I6 求解流程失效

cve / task1 · Kimi K3 · clarified · ibis。处理到最后仍未完成CVE编号归一与跨表关联，1800秒预算耗尽，没有形成最终计数链。

证据限制：保留具体未收束阶段；不能仅凭超时推断反复空转、模型思考慢或延时必然成功。

II1 任务口径与必要信息缺失或歧义

yelp / task2 · GPT-6 · direct · polars。“评论最多的州”可指商家表累计评论数，也可指评论表实际记录数。模型观察到两者赢家不同，选了前者；当次题面没有确定口径。

证据限制：保留原II1的中等/暂定置信及完整差额尚未全部解释的限制；事后hints不当作Direct实际可见信息。

II3 输出约定缺失

yelp / task6 · GLM-5.3 · clarified · pyspark。找对商家并给出一个真实类别Restaurants，但评分要求额外类别也全部列出；当次问题用单数category，未明确完整清单。

证据限制：这里缺的是输出覆盖约定，区别于I5“输出要求已经写明却没有执行”；不改历史评分。

II4 澄清信息不充分、错误或矛盾

usaspending / task8 · GPT-6 · interact · pandas。模型主动问Lockheed Martin是否包括Services子公司，澄清明确回答不包括；既有参考源码核查却采用名称包含范围。

证据限制：主因定位到实际错误澄清及执行范围；不声称已经重建参考25份完整名单或证明模型其余金额处理都正确。

模式比较与人工复核

预先补充说明与交互提问的结果不同

Direct直接求解；Clarified在初始提示中补充既有说明；Interact允许过程中提问。下表每格均为104题×4后端，即416条运行。它们属于原104题实验，不是后续12题A1 / A2 / A3减配实验。[S1、S3]

模型	Direct	Clarified	Interact	Clarified净增	Interact净增
GPT-5.5	241/416 57.9%	285/416 68.5%	254/416 61.1%	+44	+13
GPT-6	319/416 76.7%	350/416 84.1%	317/416 76.2%	+31	-2
Kimi K3	228/416 54.8%	254/416 61.1%	247/416 59.4%	+26	+19
GLM-5.3	214/416 51.4%	252/416 60.6%	230/416 55.3%	+38	+16

四个模型的Clarified通过数均高于Direct。Interact的净变化较小，GPT-6为−2条；其背后是43条未通过转为通过，同时45条通过转为未通过，不能只看净差。上述是配对描述，尚不能分离提示、工具、执行框架与交互质量的影响。

两轮人工盲标验证

两轮使用同一组按类别分层抽取的100条，包含稀有类别过采样；各自与冻结的AI主小类比较。现有人工记录按用户确认保留盲标来源及后续提交时间，不把两轮算成200条独立样本。[S5]

复核者	一致 / 不一致	一致率	Cohen κ	Macro F1
研究者	98 / 2	98%	0.9766	0.9787
老师	88 / 12	88%	0.8583	0.8874

这些数值衡量该复核样本中人工与原AI标签的一致性，不是总体分类准确率，也不是两位人工之间的一致性。全量已有主标签不等于全部经过独立人工复核。老师复核中的I2分歧主要指向I1、I3，合并时应优先核查这组边界；盲标分歧不自动覆盖正式主表。

结论适用范围

I6中204/213条来自CVE；II1中257/593条来自Civic Unstructured。按17个数据集等权后，I3 / II1 / I6占加权未通过的比例约为40.0% / 32.1% / 7.9%，原运行等权为38.6% / 32.9% / 11.8%。前两类仍居前，流程失效比例对题族构成敏感。

有效结果包含3,206条600秒预算和1,786条1800秒预算，并非全部按1800秒重跑。Stock Market task3采用已授权的事后评测修订：45条保留200字符窗口通过，余3条按500字符复评。原始答案与历史成绩保留；本文使用当前累计评分口径。

与老师材料合并及后续研究衔接

建议的合并步骤

第一步，先对齐分类对象。记录双方标注的是整次最终失败、一个中间错误片段，还是题目本身的歧义。不同对象先并列，不直接累计。

第二步，对齐定义与实例。按必要条件、排除条件和代表案例建立类别映射；可标完全对应、部分对应、待拆分、暂无对应，不能只看类别名称。

第三步，对齐运行身份和评分版本。使用模型、模式、数据集、题号、后端及结果指纹确认是否同一次有效运行。重复记录只计一次；无法对齐的先单列。

第四步，保留双方原始判断，再审分歧。分别保存本方标签、老师标签、证据、理由和最终共同裁决；尚未提供的老师意见留空，不代填。

第五步，固定合并版本后再统计。新增 / 合并类别要有映射和修订理由；受影响条目重新检查，原主表与历史统计保留。

随附逐条记录的最小字段

字段组	用途
身份与版本	sample_id、模型 / 模式 / 数据集 / 题号 / 后端、有效运行路径、结果哈希、评分修订。
结果与本方分类	生成 / 评测状态、最终是否通过、主类与小类、分类版本、次要标签。
证据与不确定性	实际输入信息、关键行为、评测联系、证据路径与位置、置信度、限制及复核状态。
老师意见与共同裁决	老师分类 / 理由、类别映射、同意或分歧、共同裁决及日期；未收到的值保持空。

RQ1 RQ2 RQ3各自回答什么

RQ1整理最终未通过的主要错误机制。RQ2据此选择可检验的信息缺口，研究删去规则和澄清指导带来的差异；“业务规则缺口 / 数据可查 / 信息充分”是操纵信息的类型，不能替代RQ1的I / II标签。RQ3分析既有104题的解题过程，纳入最终通过和未通过，追踪中间问题、修改、验证及局部修复。已修复异常不回填成RQ1的最终I4。

阅读材料与来源

S1 当前有效索引与入口；S2 DAB_ERROR_ANALYSIS v0.3及边界修订；S3 已发布四张主图的聚合数据；S4 本次九类代表案例及证据索引；S5 两轮人工复核原始标签、方法说明与指标。随附source-map.json记录完整本地路径及SHA256；evidence目录提供复算结果和合并记录。

下一步双方优先对齐I1 / I2 / I3、I3 / I6、I5 / II3边界，再处理逐条分歧。本次包整理的是已有DAB分类；老师本次新增分类或其他基准材料在收到并核对后另行合并，不将既有100条复核当作新材料。